

Identificación paramétrica y optimización de un modelo ARMAX para la dinámica respiratoria en vigilia y sueño

Mariana Vásquez Ramírez, Estefanía Loaiza Salgado

Resumen -- El presente trabajo modeló la relación dinámica entre el flujo y el esfuerzo respiratorios de un voluntario en vigilia y sueño avanzado mediante técnicas paramétricas de identificación de sistemas lineales en Python. Las señales, adquiridas a 1024 Hz, fueron preprocesadas con eliminación de tendencias, filtrado pasabajas Butterworth ($f_c = 3$ Hz), submuestreo por factor 32 y normalización estadística. Se compararon seis estructuras —AR, ARMA, ARX, ARMAX, OE y BJ— seleccionando el modelo ARMAX ($n_a=6$, $n_b=6$, $n_c=3$, $n_k=1$) por su mejor desempeño en validación. El análisis de sensibilidad identificó a_2 , a_3 , a_4 y a_5 como los parámetros más influyentes, asociados a la elasticidad pulmonar y la mecánica torácica, los cuales fueron optimizados con el algoritmo Nelder-Mead para el estado de sueño, mejorando el Fit de simulación libre de 26.06% a 54.81%. Los parámetros óptimos difirieron menos del 0.06% respecto a los de vigilia, y los coeficientes $B(q)$, que representan la transmisión mecánica del flujo al esfuerzo, permanecieron invariantes. El análisis frecuencial mostró resonancias ligeramente más pronunciadas en sueño, coherentes con la reducción del tono muscular y del drive ventilatorio cortical. En conjunto, los resultados indican que la transición de vigilia a sueño no reorganiza la dinámica respiratoria fundamental, sino que produce ajustes sutiles en el control autorregresivo, consistentes con el predominio del control automático del tronco encefálico durante el sueño normal.

I. INTRODUCCIÓN

La respiración es un proceso fisiológico complejo regulado por el sistema nervioso central mediante mecanismos automáticos y voluntarios que interactúan de forma continua. Durante el sueño, el control cortical voluntario se suprime progresivamente, quedando la ventilación bajo el gobierno casi exclusivo de los centros automáticos del bulbo raquídeo y la protuberancia. Este cambio en el control neurológico produce modificaciones observables en el patrón respiratorio: reducción de la ventilación minuto, disminución del volumen tidal y menor variabilidad ciclo a ciclo, fenómenos documentados desde estudios clásicos en adultos sanos [1]. Comprender cómo evoluciona la dinámica del sistema respiratorio entre la vigilia y el sueño tiene relevancia médica directa, pues alteraciones en estos mecanismos están asociadas a trastornos como el síndrome de apnea obstructiva del sueño, la hipoventilación nocturna y la hipoxemia en pacientes con enfermedad pulmonar obstructiva crónica [1], [2].

Para estudiar esta dinámica de forma cuantitativa, la identificación paramétrica de sistemas lineales ofrece un marco matemático riguroso que permite representar la relación entre señales fisiológicas mediante modelos en diferencias con interpretación estructural clara. Las estructuras paramétricas como ARX, ARMAX, OE y BJ han sido ampliamente utilizadas en el modelado de sistemas biomédicos porque permiten separar explícitamente la dinámica de la planta, la influencia de la entrada y el efecto del ruido, facilitando tanto la estimación de parámetros como

su interpretación fisiológica [3]. A diferencia de enfoques no paramétricos, estos modelos producen ecuaciones en diferencias directamente relacionables con las propiedades mecánicas del sistema respiratorio, como la elasticidad pulmonar, la resistencia de la vía aérea y la complianza torácica [4].

El presente trabajo tuvo como objetivo identificar un modelo paramétrico que describa la relación dinámica entre el flujo respiratorio como entrada y el esfuerzo respiratorio como salida, utilizando señales registradas en dos momentos de la noche: el inicio, con el sujeto despierto en reposo, y una etapa avanzada, con el sujeto dormido. A partir del modelo identificado en vigilia, se realizó un análisis de sensibilidad para determinar los parámetros más influyentes y se optimizaron dichos parámetros para representar la dinámica durante el sueño. Se plantea como hipótesis que la estructura dinámica fundamental del sistema respiratorio se conserva entre ambos estados, manifestándose el efecto del sueño únicamente como ajustes sutiles en los parámetros autorregresivos del modelo, coherentes con la reducción del drive ventilatorio y el predominio del control automático de la respiración durante el sueño normal [1].

II. METODOLOGÍA

A. Adquisición y descripción de las señales

Las señales utilizadas en este trabajo fueron registradas en un voluntario sano durante dos momentos distintos de la noche. Un sensor ubicado bajo la nariz registró el flujo respiratorio a la entrada de la vía aérea (mL/s), empleado como señal de entrada $u(k)$, y una banda torácica registró el esfuerzo respiratorio (u.a.), empleado como señal de salida $y(k)$. Los registros se almacenaron a una frecuencia de muestreo de 1024 Hz, con 30720 muestras por segmento (aproximadamente 30 segundos). El conjunto de datos quedó organizado en tres segmentos según lo descrito en la Tabla I.

B. Preprocesamiento de las señales

Previo a la identificación se aplicó una cadena de preprocesamiento para eliminar componentes no asociadas a la dinámica respiratoria y garantizar la comparabilidad entre segmentos. Primero se eliminó la tendencia de cada señal mediante *detrend* para remover componentes de muy baja frecuencia no relacionadas con el ciclo respiratorio. Posteriormente, se analizó la densidad espectral de potencia (PSD) mediante el método de Welch, cuyos resultados se presentan en la Fig. 1. Como se observa en dicha figura, la energía de ambas señales se concentra principalmente entre 0 y 2 Hz, con un pico dominante alrededor de 0.3–0.5 Hz correspondiente a la frecuencia respiratoria del voluntario en reposo, valor coherente con una frecuencia normal de 15–20

respiraciones por minuto. A partir de 3 Hz la potencia de ambas señales decae varios órdenes de magnitud, confirmando que el contenido fisiológico relevante se encuentra completamente dentro de esta banda. Con base en este análisis, se diseñó un filtro pasa-bajas Butterworth de orden 4 con $f_c = 3$ Hz, aplicado de forma bidireccional mediante *filtfilt* para evitar distorsión de fase [3]. Posteriormente se realizó un submuestreo por factor 32, reduciendo la frecuencia de muestreo de 1024 Hz a 32 Hz, frecuencia que supera ampliamente el criterio de Nyquist para la banda respiratoria y evita predicciones triviales por sobremuestreo. Finalmente, se aplicó normalización estadística con media cero y desviación estándar unitaria usando los estadísticos del segmento de estimación, aplicando la misma escala a los segmentos de validación y sueño para garantizar comparabilidad entre estados.

C. Identificación paramétrica del sistema

La identificación se realizó mediante seis estructuras paramétricas en tiempo discreto que representan la relación entrada-salida mediante polinomios en el operador de retardo q^{-1} [2]. El modelo AR, dado por la ecuación (1), y el modelo ARMA, expresado en la ecuación (2), describen la salida sin entrada explícita y fueron incluidos como referencia comparativa. El modelo ARX, mostrado en la ecuación (3), introduce la entrada con ruido aditivo directo. El modelo ARMAX, presentado en la ecuación (4), combina entrada explícita con media móvil sobre el ruido. El modelo OE, definido en la ecuación (5), separa la dinámica de la planta del ruido aditivo, y el modelo BJ, expresado en la ecuación (6), generaliza esta separación con polinomios independientes para planta y ruido. Los polinomios $A(q)$ y $B(q)$ que comparten estas estructuras se definen en las ecuaciones (7) y (8). Los candidatos principales para la selección final fueron ARX, ARMAX, OE y BJ por incorporar la entrada explícita, requisito indispensable para describir la relación flujo-esfuerzo.

Los parámetros fueron estimados por mínimos cuadrados sobre la matriz de regresión construida con los retardos de entrada y salida [2], con $n_a = 6$, $n_b = 6$, $n_k = 1$ y $n_c = 3$ para las estructuras que lo requieren. La selección del modelo final se basó en el porcentaje de ajuste Fit, ecuación (9), y el RMSE, ecuación (10), evaluados sobre señales de validación independientes, priorizando el Fit de simulación libre por ser la métrica más exigente para evaluar la dinámica entrada-salida real del sistema [2].

D. Análisis de sensibilidad

Para determinar los parámetros más influyentes del modelo seleccionado se realizó un análisis de sensibilidad normalizada según la ecuación (11), donde cada parámetro θ_i fue perturbado un 1% ($\Delta = 0.01$) y se cuantificó el cambio relativo producido en la salida estimada durante validación. Los cuatro parámetros con mayor S_i fueron seleccionados para la etapa de optimización [2].

E. Optimización de parámetros para el estado de sueño

Manteniendo fija la estructura ARMAX identificada en vigilia, los cuatro parámetros más sensibles fueron optimizados minimizando la función de costo MSE definida en la ecuación (12) sobre las señales de sueño. La minimización se realizó con el algoritmo Nelder-Mead. Como valores semilla se utilizaron los parámetros identificados en vigilia, dado que ambos estados corresponden al mismo sistema fisiológico.

F. Análisis en tiempo y frecuencia

Para comparar el comportamiento dinámico de ambos modelos se construyó la función de transferencia discreta $G(z) = B(z)/A(z)$ y se obtuvieron los diagramas de Bode a 32 Hz. El análisis temporal consistió en la simulación libre de ambos modelos sobre sus respectivas señales, evaluando cuantitativamente el desempeño mediante Fit y RMSE.

A. Presentación de ecuaciones

$$A(q)y(k) = e(k) \quad (1)$$

$$A(q)y(k) = C(q)e(k) \quad (2)$$

$$A(q)y(k) = B(q)u(k) + e(k) \quad (3)$$

$$A(q)y(k) = B(q)u(k) + C(q)e(k) \quad (4)$$

$$y(k) = \frac{B(q)}{F(q)}u(k) + e(k) \quad (5)$$

$$y(k) = \frac{B(q)}{F(q)}u(k) + \frac{C(q)}{D(q)}e(k) \quad (6)$$

$$A(q) = 1 + a_1q^{-1} + \dots + a_{n_a}q^{-n_a} \quad (7)$$

$$B(q) = b_1q^{-n_k} + \dots + b_{n_b}q^{-(n_k+n_b-1)} \quad (8)$$

$$Fit (\%) = 100 \left(1 - \frac{\|y - \hat{y}\|}{\|y - \bar{y}\|} \right) \quad (9)$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{k=1}^N (y(k) - \hat{y}(k))^2} \quad (10)$$

$$S_i = \frac{\|\hat{y}_{\theta_i + \Delta \theta_i} - \hat{y}_{\theta}\|}{\|\hat{y}_{\theta}\|} \cdot \frac{1}{\Delta} \quad (11)$$

$$J(\theta) = \frac{1}{N} \sum_{k=1}^N (y_{real}(k) - y_{modelo}(k))^2 \quad (12)$$

B. Presentación de tablas

Tabla 1. Señales registradas durante dos momentos de la noche para identificación y validación del modelo.

Segmento	Descripción	Entrada	Salida	Tiempo
Estimación	Inicio de la noche, sujeto despierto en reposo	U1	Y1	T1
Validación	Inicio de la noche, segmento independiente	UV	YV	TV
Sueño	Etapas avanzadas de la noche, sujeto dormido	U2	Y2	T2

C. Presentación de Figuras




Figura 1 Densidad espectral de potencia (PSD) de las señales de flujo respiratorio y esfuerzo torácico estimada mediante el método de Welch.

III. RESULTADOS

A. Selección de la Estructura y el Orden del Modelo

Tras evaluar seis estructuras paramétricas, se seleccionó el modelo ARMAX con un orden ($na = 6$, $nb = 6$, $nk = 1$, $nc = 3$), lo que resulta en un sistema de 15 parámetros. Esta elección cumple con la exigencia de superar los 4 parámetros para capturar la complejidad del sistema. Como se observa en la Tabla II, aunque todas las estructuras presentan un ajuste cercano al 100% en la predicción a un paso (debido al uso de datos reales previos), el modelo ARMAX/BJ sobresale en la simulación libre, logrando un Fit de 26.06%. Esta métrica es la más robusta para validar la capacidad del modelo de representar la relación flujo-esfuerzo sin correcciones externas

Tabla 2 Comparación de desempeño entre estructuras paramétricas (estimación en vigilia).

Estructura	Orden	Parámetros	Fit	Fit	RMSE
			Predicción [%]	Simulación [%]	
ARMAX	15	$na=6,$ $nb=6,$ $nk=1,$ $nc=3$	99.99%	26.06%	0,73
BJ	15	$na=6,$ $nb=6,$ $nk=1,$ $nc=3$	99.99%	26.06%	0,73
ARX	12	$na=6,$ $nb=6,$ $nk=1,$ $nc=0$	99.99%	18.01%	0,81
OE	12	$na=6,$ $nb=6,$ $nk=1,$ $nc=0$	99.99%	18.01%	0,81

ARMA	9	$na=6,$ $nb=0,$ $nk=1,$ $nc=3$	99.99%	12.78%	0,861
AR	6	$na=6,$ $nb=0,$ $nk=1,$ $nc=0$	99.99%	10.71%	0,882

B. Identificación de Parámetros Críticos

El análisis de sensibilidad normalizada permitió determinar qué coeficientes del modelo tienen mayor impacto en la salida estimada. Los resultados presentados en la Figura 1 identifican a a_3 , a_4 , a_2 y a_5 como los cuatro parámetros más sensibles. Estos coeficientes, pertenecientes al polinomio $A(q)$, representan la dinámica interna y la memoria del sistema. El hecho de que los parámetros más influyentes sean autorregresivos sugiere que el esfuerzo respiratorio está gobernado primordialmente por sus propios estados previos y las propiedades mecánicas pasivas del tórax, más que por cambios instantáneos en el flujo




Figura 2. Gráfico de barras de sensibilidad de parámetros

Los parámetros seleccionados muestran valores de sensibilidad que superan significativamente a los coeficientes de entrada (b_i), indicando que pequeñas variaciones en la dinámica interna del sistema alteran drásticamente la precisión del modelo.

C. Desempeño Temporal y Optimización en Sueño

Al optimizar los parámetros sensibles para el estado de sueño profundo, el desempeño del modelo mejoró notablemente. Como se aprecia en la Figura 2, la simulación libre en el estado de sueño alcanzó un Fit del 54.81%, frente al 26.06% obtenido en vigilia. Fisiológicamente, este aumento en la precisión se debe a que la respiración durante el sueño se vuelve más regular y estereotipada, lo que facilita su representación mediante un modelo lineal estacionario al reducirse la variabilidad voluntaria cortical




Figura 3. Comparación de simulación libre: Sueño real vs. Simulado

Se observa visualmente cómo el modelo de sueño sigue con mayor fidelidad la amplitud y periodicidad de la señal real, reflejando un sistema con una dinámica interna más estable y predecible bajo control automático.

D. Respuesta Frecuencial del Sistema

El análisis en el dominio de la frecuencia, presentado en el diagrama de Bode de la Figura 4, muestra que ambos estados conservan una estructura de resonancia similar, pero con diferencias de magnitud críticas. El modelo de sueño exhibe una ganancia superior de aproximadamente 8 dB en la zona de resonancia de baja frecuencia (30–50 rad/s) en comparación con el de vigilia




Figura 4. Respuesta en magnitud - Diagrama de Bode

Esta mayor ganancia en las resonancias durante el sueño se interpreta como una menor amortiguación activa del sistema respiratorio, consecuencia directa de la reducción del tono muscular y del drive ventilatorio durante las etapas profundas del sueño. Por encima de los 500 rad/s, ambos modelos convergen, actuando como un filtro pasa-bajas debido a la inercia mecánica del aparato respiratorio que permanece invariante

IV. DISCUSIÓN

La identificación del sistema respiratorio mediante estructuras paramétricas permitió cuantificar los cambios en la dinámica flujo-esfuerzo durante la transición de la vigilia al sueño profundo. Los resultados obtenidos demuestran que, aunque la estructura mecánica fundamental del sistema permanece esencialmente invariante, los mecanismos de control neurológico modifican de manera significativa la respuesta dinámica observada. Este tipo de análisis es consistente con los principios de identificación de sistemas, donde los modelos paramétricos permiten representar el comportamiento dinámico de procesos fisiológicos complejos mediante un conjunto reducido de parámetros interpretables [3], [4].

El incremento en el porcentaje de ajuste del modelo durante el sueño (Fit del 54.81 % frente al 26.06 % en vigilia) constituye uno de los hallazgos más relevantes del estudio. Esta mejora en la capacidad predictiva puede atribuirse a la mayor regularidad del patrón respiratorio durante el sueño. A medida que el individuo transita desde la vigilia hacia etapas más profundas del sueño, disminuye progresivamente la influencia del control cortical voluntario sobre la respiración y predomina la regulación automática ejercida por los centros respiratorios del tronco encefálico [1], [2]. Douglas et al. reportaron que durante el sueño no REM la respiración presenta una menor variabilidad y una mayor estabilidad temporal en comparación con la vigilia, favoreciendo la descripción del sistema mediante modelos lineales estacionarios [1].

Desde la perspectiva frecuencial, la mayor ganancia observada en las zonas de resonancia durante el sueño, con un incremento aproximado de 8 dB, sugiere una disminución de los mecanismos de amortiguación activa presentes en estado de vigilia. Este comportamiento es coherente con la reducción generalizada del tono muscular y del impulso ventilatorio central característica del sueño normal, fenómenos ampliamente documentados en la fisiología respiratoria relacionada con el sueño [2]. La disminución de estas influencias regulatorias contribuye a que la dinámica respiratoria sea más predecible y, por tanto, más susceptible de ser capturada por modelos paramétricos de identificación [3], [4].

Por otro lado, la invarianza observada en los coeficientes asociados al polinomio $B(q)$ indica que la relación mecánica entre el flujo de aire y el esfuerzo torácico permanece prácticamente constante entre ambos estados fisiológicos. Este resultado sugiere que las propiedades estructurales del sistema respiratorio, tales como la resistencia de las vías aéreas y la elasticidad pulmonar, no experimentan modificaciones significativas durante la transición entre vigilia y sueño, mientras que los cambios observados se concentran principalmente en los mecanismos de regulación neural [1], [2]. Desde el punto de vista de la identificación de sistemas, esta estabilidad estructural es coherente con la existencia de una misma planta dinámica cuyos parámetros pueden experimentar variaciones asociadas a cambios en las condiciones de operación del sistema [4].

En conclusión, el modelo identificado no solo logró representar adecuadamente la dinámica respiratoria, sino que también permitió diferenciar los efectos asociados a la mecánica pasiva del sistema de aquellos derivados de la regulación neural. Los resultados obtenidos respaldan la hipótesis de una estructura dinámica persistente con modificaciones paramétricas dependientes del estado fisiológico, demostrando la utilidad de las técnicas de identificación de sistemas para el estudio cuantitativo de procesos biomédicos y de los cambios fisiológicos asociados al sueño [3], [4].

V. CONCLUSION

El estudio permite concluir que la dinámica del sistema respiratorio, analizada a través de la relación entre el flujo de aire y el esfuerzo torácico, experimenta una transición hacia un comportamiento significativamente más predecible y regular durante el sueño profundo. Este fenómeno se manifiesta técnicamente en el notable incremento del ajuste del modelo ARMAX seleccionado, el cual pasó de un Fit de 26.06% en vigilia a un 54.81% en sueño. Fisiológicamente, esta mejora en la predictibilidad responde a la supresión del control cortical voluntario, lo que deja la ventilación bajo el mando casi exclusivo de los centros automáticos del tronco encefálico, volviendo el patrón respiratorio más estereotipado y apto para ser representado por modelos lineales estacionarios.

En cuanto a la estructura del sistema, los resultados demuestran que la planta mecánica fundamental permanece invariante entre ambos estados, ya que los coeficientes que representan la transmisión mecánica del flujo al esfuerzo (polinomio $B(q)$) no sufrieron cambios significativos. No obstante, el sueño sí induce ajustes sutiles pero detectables en la dinámica interna del sistema, específicamente en los parámetros autorregresivos a_2 , a_3 , a_4 y a_5 , los cuales están vinculados a la elasticidad pulmonar y la memoria mecánica del tórax. El hecho de que las variaciones en estos parámetros óptimos fueran menores al 0.06% respecto a la vigilia confirma que el sistema no se reorganiza por completo, sino que simplemente ajusta su regulación interna.

El análisis en el dominio de la frecuencia refuerza esta interpretación al mostrar que el modelo en estado de sueño presenta resonancias de baja frecuencia significativamente más pronunciadas, con un incremento de ganancia de aproximadamente 8 dB en comparación con la vigilia. Esta mayor amplitud en las resonancias indica una menor amortiguación activa del sistema respiratorio, lo cual es coherente con la reducción generalizada del tono muscular y del drive ventilatorio cortical que caracteriza las etapas profundas del sueño. Al mismo tiempo, la convergencia de ambos modelos en frecuencias altas demuestra que la inercia mecánica del aparato respiratorio es una propiedad física que se mantiene constante independientemente del estado de conciencia.

Finalmente, el trabajo valida la hipótesis de que la estructura dinámica del sistema respiratorio se conserva durante la transición al sueño, manifestándose el cambio de estado únicamente como ajustes sutiles en el control autorregresivo. La aplicación de técnicas de identificación paramétrica no solo permitió representar con éxito estos procesos biológicos complejos, sino que también facilitó la diferenciación entre los componentes mecánicos pasivos y los mecanismos de regulación neural activos. Este enfoque cuantitativo resulta fundamental para comprender mejor la fisiología respiratoria normal y proporciona herramientas robustas para el estudio de patologías asociadas a trastornos del sueño

[1] N. J. Douglas, D. P. White, C. K. Pickett, J. V. Weil, and C. W. Zwillich, "Respiration during sleep in normal man," *Thorax*, vol. 37, no. 11, pp. 840–844, Nov. 1982. [Online]. Available: <https://thorax.bmj.com/content/37/11/840>

[2] Schäfer T. Respiratory pathophysiology: sleep-related breathing disorders. *GMS Curr Top Otorhinolaryngol Head Neck Surg*. 2006;5:Doc01. Epub 2006 Oct 5. PMID: 22073070; PMCID: PMC3199805. <https://pmc.ncbi.nlm.nih.gov/articles/PMC3199805/>

[3] I. Chinchay y W. Ipanaqué, "Identificación de un modelo para un control de pH," Universidad de Piura, Piura, Perú, 2011. https://www.academia.edu/9519370/IDENTIFICACION_D_E_SISTEMAS

[4] L. Ljung, *System Identification: Theory for the User*, 2nd ed. Englewood Cliffs, NJ, USA: Prentice Hall, 1999. https://www.mit.bme.hu/data/migrate/oktatas/targyak/9132/Ljung_L_System_Identification_Theory_for_User-ed2.pdf